

Inteligencia Artificial para el Análisis del Descanso de las Vacas: Nueva Distribución

María Fernanda Moreno Gómez

A01708653@tec.com

ABSTRACT

El descanso adecuado del ganado lechero es un indicador clave de su bienestar y productividad. Este estudio presenta un análisis comparativo entre dos enfoques de inteligencia artificial aplicados a imágenes recolectadas en el CAETEC, un rancho lechero: un modelo de red neuronal convolucional (CNN) entrenado desde cero y un modelo basado en transferencia de aprendizaje. Las imágenes, capturadas cada cinco minutos durante el día, fueron clasificadas en tres estados de ocupación por cama: vacía, vaca acostada y vaca parada. Se analizó la distribución horaria del comportamiento de descanso y la ocupación por cama, utilizando datasets de los años 2024 y 2025. Los resultados revelan patrones consistentes de descanso nocturno, con diferencias significativas en la preferencia por ciertas camas, lo cual puede estar influenciado por factores ambientales o estructurales. Asimismo, se observó que el modelo con transfer learning ofreció un rendimiento superior en términos de generalización y precisión, facilitando un análisis más confiable del comportamiento animal. Este enfoque contribuye al monitoreo eficiente del bienestar del ganado mediante inteligencia artificial, promoviendo una ganadería más eficiente y tecnológica.

1. INTRODUCCIÓN

Anteriormente, se había trabajado en conjunto con el rancho CAETEC, perteneciente al Tecnológico de Monterrey, con el fin de analizar los estados de las vacas en las camas y determinar si estas están descansando en ellas, así como estudiar los datos obtenidos para comprender su comportamiento. Con el modelo anterior, el Modelo 3, se logró entrenar una red neuronal convolucional (CNN) desde cero para clasificar imágenes capturadas cada cinco minutos por una cámara instalada frente a tres camas (A, B y C), identificando tres posibles estados: cama vacía, vaca acostada y vaca parada. Este enfoque permitió observar patrones generales de descanso y uso de las camas, brindando una primera aproximación al

análisis automatizado del comportamiento de las vacas.

Sin embargo, al tratarse de un modelo entrenado desde cero, su desempeño estaba limitado por la cantidad y diversidad del dataset original, lo que afectaba su capacidad de generalización y requería tiempos de entrenamiento considerables. Por ello, en esta nueva etapa del proyecto, se propuso la implementación de un modelo basado en Transfer Learning (Modelo 4), técnica que permitió tomar el aprendizaje obtenido del modelo anterior y ajustarlo con más imágenes de vaca de pie principalmente para evitar que falle en esta categoría.

El nuevo modelo fue entrenado con un nuevo conjunto de imágenes correspondientes al año 2025, donde se

analizaron dos camas (A y B, que corresponden a las camas B y C respectivamente del modelo anterior), con el objetivo de mejorar la precisión del sistema de clasificación y realizar un análisis comparativo con los resultados obtenidos en 2024. Este artículo tiene como objetivo presentar una evaluación detallada de ambos modelos, enfocar el análisis en la distribución horaria del descanso de las vacas, identificar cambios en las preferencias por cama entre años, y explorar posibles factores que influyen en estos comportamientos.

2. DESCRIPCIÓN DEL DATASET

El nuevo conjunto de datos, denominado "Beds", consta de un total de 15,140 imágenes en formato JPG, con dimensiones de 1920 x 1080 px. Las imágenes fueron proporcionadas por el Dr. Ivo Ayala a través de una unidad compartida en OneDrive. El tamaño de las imágenes varía entre 188 KB y 678 KB, dando un total de 7.13 GB para todo el dataset.

2a.- Recolección de imágenes

Las imágenes fueron capturadas con una cámara web marca Logitech, colocada en la parte superior del área de descanso del rancho. Esta posición permitió captar dos camas para vacas y el área del bebedero en cada imagen.

3. MANEJO DE DATOS

3a.- Diferencias Entre el Primer Dataset con el Nuevo Dataset

En el conjunto de datos anterior se contaba con 9,634 imágenes tomadas en el año 2024, donde era posible visualizar tres

camas completas. En cambio, el nuevo dataset comprende 15,140 imágenes capturadas entre el 1° de enero y el 24 de marzo de 2025, y solo se observan dos camas completas, ya que se amplió el encuadre para incluir también el área del bebedero.

3b.- Asignación de Etiquetas y Organización

Dado que este trabajo es una extensión del proyecto previamente desarrollado, se reutiliza el modelo de inteligencia artificial original para clasificar las nuevas imágenes con las mismas etiquetas:

- Vaca parada
- Vaca acostada
- Cama sin vaca

Para esta fase, se decidió etiquetar manualmente una muestra representativa del nuevo conjunto de datos. En total, se etiquetaron 576 imágenes, lo que equivale a 1,152 camas, ya que cada imagen contiene dos espacios de cama para vacas.

El total de camas disponibles en el dataset es de 30,280 camas (resultado de 15,140 imágenes $\times$ 2 camas por imagen). Para determinar el tamaño mínimo necesario de la muestra, se utilizó la fórmula para el cálculo de tamaño de muestra para poblaciones finitas [1]:

$$n = \frac{N \cdot Z^2 \cdot p \cdot q}{(N - 1) \cdot e^2 + Z^2 \cdot p \cdot q}$$

Figura 1: Fórmula para obtener el tamaño de muestra de una población.

Donde:

- $N=30,280$ (total de camas en la población)
- $Z=1.96$ (nivel de confianza del 95%)
- $p=0.5$ y $q=0.5$ (proporción máxima de variabilidad)
- $e= 0.03$ (margen de error del 3%)

Sustituyendo los valores:

$$n = \frac{30280 \cdot 1.96^2 \cdot 0.5 \cdot 0.5}{(30280 - 1) \cdot 0.03^2 + 1.96^2 \cdot 0.5 \cdot 0.5} \approx 1,030$$

Figura 2: Sustitución de la fórmula con los valores reales para obtener el tamaño de muestra de una población.

Se obtiene entonces un tamaño de muestra mínimo de aproximadamente 1,030 camas. Por lo tanto, el etiquetado de 1,152 camas cumple con los requisitos estadísticos para representar adecuadamente la población, proporcionando una base confiable para validar el modelo.

La elección específica de 576 imágenes responde a la frecuencia con la que fueron tomadas: cada imagen fue capturada a intervalos de 5 minutos, lo cual genera 288 fotografías por día. Para abarcar al menos dos días completos de observación, se seleccionaron 576 imágenes, permitiendo así comparar comportamientos en los mismos intervalos horarios en días distintos.

3c.- Distribución de Clases en la Muestra

- 48 camas con vacas de pie
- 283 camas con vacas acostadas
- 821 camas vacías

Esta distribución refleja el comportamiento típico observado en el área de descanso del rancho CAETEC y servirá como base para evaluar la

capacidad del modelo previamente realizado para generalizar nuevas imágenes.

3d.- Objetivo del Etiquetado

El objetivo de esta etapa de etiquetado no es volver a entrenar el modelo, sino evaluar su desempeño sobre el nuevo conjunto de datos. Las etiquetas manuales servirán como referencia real (ground truth) para generar métricas de evaluación, como:

- Matriz de confusión
- Precisión (accuracy)
- Precisión por clase
- F1-score

Estas métricas permitirán determinar si el modelo conserva un buen nivel de precisión frente a imágenes nuevas que presentan diferencias en ángulo, iluminación o entorno, asegurando su robustez y aplicabilidad práctica.

4. CONSTRUCCIÓN DEL MODELO

A continuación, se presenta el proceso de construcción y ajuste del modelo de red neuronal convolucional (CNN) empleado para la clasificación automática de imágenes en tres clases: vaca de pie, vaca acostada y cama vacía. La presente versión del modelo surge como una iteración y mejora sobre una versión anterior, que, si bien ya ofrecía resultados aceptables, presentaba áreas de oportunidad en términos de robustez, adaptabilidad y estabilidad durante el entrenamiento.

4a.- Arquitectura del Modelo

El modelo base llamado “SimpleCNN.py” mantiene una estructura simple y eficiente, compuesta por dos bloques principales: un

bloque convolucional para la extracción de características y un bloque de capas densamente conectadas para la clasificación.

- *4a.1.- Capa convolucional*

La arquitectura inicial y la actual comparten el mismo diseño en esta sección. Ambas versiones implementan una única capa convolucional con las siguientes características:

- **Entrada:** imágenes de 3 canales (RGB).
- **Salida:** 16 mapas de características.
- **Filtros:** kernel de tamaño 3x3 con padding=1
- **Activación:** ReLU.
- **Reducción espacial:** MaxPool2D con ventana de 2x2

Esta configuración permite al modelo capturar patrones básicos como bordes y texturas, manteniendo bajo control la complejidad computacional.

- *4a.2.- Capas densas*

Ambas versiones del modelo utilizan una secuencia idéntica de capas *Linear* para la clasificación final, iniciando desde la salida de la capa convolucional (16 * 225 * 475) hasta alcanzar las tres clases previstas. Las capas intermedias están acompañadas de funciones ReLU para incorporar no linealidad y permitir al modelo aprender relaciones complejas. La última capa devuelve tres valores (uno para cada clase) y, en ambos casos, se omite la función Softmax, ya que la función de pérdida CrossEntropyLoss la integra internamente.

4b.- Diferencias y Mejoras Implementadas

Aunque la estructura arquitectónica en términos de capas no sufrió cambios entre el modelo anterior y el actual, sí se realizaron ajustes específicos en la fase de entrenamiento y preparación de datos, orientados a mejorar la capacidad de generalización y estabilidad del modelo durante el proceso de aprendizaje supervisado.

- *4b.1.- Aumento de Datos (Data Augmentation)*

Ambas versiones aplican un conjunto de transformaciones sobre las imágenes de entrada para aumentar la variabilidad y robustez del modelo frente a condiciones reales. Sin embargo, se realizaron ajustes en los parámetros para garantizar resultados más consistentes.

En se implementaron las siguientes transformaciones:

Transformación	Versión Anterior	Versión Actual
Resize	(950, 450)	Igual
RandomHorizontalFlip	p=0.5	Igual
RandomVerticalFlip	p=0.5	Igual
RandomRotation	$\pm 30^\circ$	Igual
RandomAffine	scale=(0.5, 1.0)	Igual
ColorJitter	saturation=2	brillo = 0.3 contraste = 0.2

Normalize	mean=[0.5, 0.5, 0.5], std=[0.5, 0.5, 0.5]	Igual
-----------	--	-------

Tabla 1: Comparación de transformaciones entre el modelo 3 y el nuevo modelo (3.1).

El cambio más relevante fue el aumento de la saturación de color, pasando de un factor 2 en la versión anterior a 3 en la versión actual, buscando aumentar la sensibilidad del modelo ante variaciones de iluminación y contraste que ocurrió específicamente al tener una sombra oscura en la cama pegada a la barda del bebedero de las vacas.

Con esta modificación se busca que el modelo pueda identificar los colores de la vaca aun cuando la iluminación no sea la mejor específicamente en esta cama.

- *4b.2.- Ponderación de Clases en la Función de Pérdida*

El modelo utiliza la función de pérdida CrossEntropyLoss con pesos personalizados para manejar el desbalance de clases. En la versión actual se ajustaron estos pesos de la siguiente forma:

Clase	Peso Anterior	Peso Actual
Cama vacía	3	5
Vaca acostada	1	1
Vaca de pie	9	10

Tabla 2: Comparación de pesos entre el modelo 3 y el nuevo modelo (3.1).

El ajuste tuvo como objetivo reforzar aún más la importancia de la clase "vaca de pie", elevando su peso de 9.0 a 10.0, y también aumentar la relevancia de la clase "cama vacía" de 3.0 a 5.0. Esto fue producto de la observación de un sesgo recurrente en las predicciones hacia clases mayoritarias durante las pruebas preliminares, pues al no tener tantas imágenes en el entrenamiento en "vaca de pie", estas resultaban ser las menos predichas en las evaluaciones del modelo preliminares.

5. RESULTADOS MODELO 3.1

Una vez finalizado el entrenamiento del modelo propuesto, se evaluó su desempeño utilizando tanto el conjunto de prueba original como un nuevo conjunto adicional con diferente distribución y condiciones de captura.

5a.- Evaluación con el Dataset Nuevo

Para validar la robustez y capacidad de generalización del modelo entrenado, se utilizó el segundo conjunto de imágenes mencionado anteriormente, conformado por imágenes donde solo se observan dos camas por imagen en lugar de las tres. Esto supuso un reto distinto para el modelo, ya que las condiciones espaciales y de composición visual variaban ligeramente respecto a los datos con los que fue entrenado.

El conjunto de prueba adicional comprendió un total de 576 imágenes, distribuidas de la siguiente manera en términos de clases:

- 48 camas con vacas de pie
- 283 camas con vacas acostadas
- 821 camas vacías

Tras la evaluación, los resultados de clasificación obtenidos por el modelo fueron:

- 54 camas con vacas de pie
- 412 camas con vacas acostadas
- 686 camas vacías

Conteo total de clases:	
cama_vacia	686
vaca_acostada	412
vaca_parada	54

Figura 3: Conteo total de las predicciones en cada estado.

Aunque el modelo mostró cierta desviación, particularmente sobrestimando las instancias de "vaca acostada" y subestimando "cama vacía", el comportamiento general indicó que el modelo ha logrado una capacidad de generalización aceptable frente a cambios en la disposición espacial de las camas.

5b.- Evaluación Global: Matriz de Confusión

Para una evaluación integral, ambos conjuntos de datos (el original y el adicional) fueron combinados y se calculó la matriz de confusión final, que se muestra en la siguiente figura:

La matriz revela que el modelo logró clasificar con alta precisión la clase mayoritaria "cama vacía" con 1,320 verdaderos positivos, mientras que las clases minoritarias como "vaca acostada" y "vaca de pie" presentaron resultados más conservadores, destacando especialmente:

- **Vaca acostada:** 335 verdaderos positivos, con 30 falsos negativos y 29 falsos positivos.

- **Vaca de pie:** 33 verdaderos positivos, con 23 falsos negativos y 4 falsos positivos.

Estos resultados sugieren que, aunque el modelo muestra un alto grado de precisión en la clase predominante, continúa enfrentando retos a la hora de distinguir con exactitud las clases minoritarias, esto es debido principalmente al desbalance en la distribución de los datos y a las limitaciones visuales que se tienen debido a las condiciones de iluminación y/o ángulo de la cámara.




Figura 4: Matriz de confusión de ambos datasets.

6. TRANSFER LEARNING

Con el objetivo de mejorar específicamente la detección de la categoría "vaca de pie", se optó por aplicar una técnica de aprendizaje automático conocida como Transfer Learning.

Transfer Learning consiste en aprovechar el conocimiento adquirido por un modelo previamente entrenado en una tarea diferente pero relacionada, para mejorar el desempeño en una nueva tarea específica [2]. Esta estrategia resulta especialmente útil en situaciones donde se dispone de

conjuntos de datos limitados, como es nuestro caso.

En lugar de entrenar un modelo desde cero (lo cual requiere recursos computacionales considerables y más tiempo), Transfer Learning permite reutilizar las características generales que un modelo ya ha aprendido y adaptarlas a un nuevo contexto más específico.

En este proyecto, el uso de Transfer Learning busca contrarrestar los efectos del overfitting que pueden surgir debido a la escasez de ejemplos en clases minoritarias [3], como "vaca de pie". De esta forma, el modelo no solo mejora su precisión general, sino también su capacidad de generalizar a nuevas imágenes con variaciones en iluminación, ángulo o entorno, asegurando un rendimiento más robusto en condiciones reales.

Esta técnica permite, en esencia, "transferir" el aprendizaje de un dominio amplio a un dominio más específico, acelerando el proceso de entrenamiento y logrando resultados de mayor calidad incluso con datasets reducidos.

A continuación, se presenta la implementación del nuevo modelo con Transfer Learning.

6a.- Selección y Carga del Modelo base

Se utilizó como modelo base la CNN descrita en la sección 4 de este documento entrenado (con las 3,997 imágenes originales del proyecto anterior) con 8,803 archivos de imágenes de camas vacías, 2,625 archivos de imágenes de camas con vaca acostada y 397 archivos de imagen con vaca parada, dando como resultado el

archivo *model_acc_95.32.pth*, el cual, es nuestro modelo base para el Transfer Learning.

6b.- Congelación de Capas

Para evitar que se pierda el conocimiento previamente aprendido en las capas convolucionales, estas se congelaron desactivando el cálculo de gradientes. De este modo, durante el entrenamiento, solo las capas densas fueron actualizadas [3].

Las capas densas (también conocidas como fully connected layers) son aquellas donde cada neurona recibe como entrada todos los valores de la capa anterior, aplica una combinación lineal ponderada (a través de pesos y sesgos) y, posteriormente, una función de activación [4]. Estas capas permiten que el modelo aprenda relaciones complejas y patrones a partir de las características extraídas por las capas convolucionales.

6c.- Preparación de los Datos

Se siguió utilizando data augmentation para incrementar la diversidad de los datos y que el modelo pueda aprender con datos distintos. Las transformaciones aplicadas se pueden ver en la sección 4b.1, que son las mismas que las que se utilizaron en el modelo con Transfer Learning.

6d.- Ponderación de Clases en la Función de Pérdida

Se sigue utilizando la función de pérdida CrossEntropyLoss como se muestra en la sección 4b.2. Sin embargo, los pesos asignados a cada clase fueron modificados en los distintos modelos para reflejar tanto el desbalance en el número de ejemplos

como la importancia relativa de cada estado:

Clase	Peso Modelo 3	Peso Modelo 3.1	Peso Modelo 4 (con TL)
Cama vacía	3	5	2
Vaca acostada	1	1	4
Vaca de pie	9	10	7

Tabla 3: Comparación de pesos entre el modelo 3, el modelo (3.1) y el modelo 4 (con transfer learning).

En el Modelo 3, los pesos iniciales se asignaron para penalizar más los errores en la detección de vacas de pie, dado que estas instancias eran menos frecuentes y más críticas para el análisis del comportamiento.

En el Modelo 3.1, se incrementó aún más el peso de la clase "vaca de pie" y de "cama vacía" para reforzar la correcta detección de estos estados, ya que los errores en estas categorías afectaban más la interpretación de la ocupación de las camas.

Finalmente, en el Modelo 4, al aprovechar un modelo preentrenado, se reequilibraron los pesos, dándole más importancia a la clase "vaca acostada", que anteriormente se le había dado más peso, y reduciendo ligeramente el peso de "cama vacía" y "vaca de pie" para evitar un sobreajuste del modelo hacia ellas.

En todos los casos, el objetivo principal de la ponderación fue mejorar el desempeño en clases minoritarias o más difíciles de identificar, compensando el desbalance en la distribución del dataset y focalizando el aprendizaje hacia las clases de mayor relevancia para el proyecto.

6e.- Entrenamiento en las Capas Superiores

El entrenamiento consistió en un número reducido de épocas (20 épocas), dado que el modelo ya contaba con conocimiento previo y únicamente era necesario ajustar las capas densas a las nuevas imágenes.

6f.- Evaluación del Modelo Ajustado

Una vez finalizado el entrenamiento de las capas superiores, se evaluó el desempeño del modelo utilizando las imágenes del conjunto de datos de prueba preparado para este proyecto.

Se calcularon métricas clave como la precisión global (accuracy), matriz de confusión y el informe de clasificación que incluye precisión (precision) y F1-score.

Esta evaluación permitió validar que la transferencia de aprendizaje y el ajuste de las capas densas efectivamente mejoraron la adaptación del modelo a las nuevas imágenes, confirmando que el conocimiento previo fue aprovechado de manera efectiva.

7. RESULTADOS CON TRANSFER LEARNING




Figura 5: Matriz de confusión modelo 4 (Con transfer learning).

```

=== Accuracy estimada por cama ===
Cama A: 0.9583 (552 de 576 coincidencias)
Cama B: 0.9896 (570 de 576 coincidencias)

```

Figura 6: Accuracy global por cama.

Analizando la matriz de confusión, podemos ver una gran mejoría en la clasificación de camas vacías, pues logra clasificar 815 imágenes correctamente de las 831, logrando clasificar correctamente el 98.07% del total de imágenes de esta categoría.

Por otro lado, la categoría “vaca acostada” logró clasificar correctamente 275 imágenes de las 298 disponibles, logrando clasificar correctamente el 92.28% del total de imágenes de esta categoría.

Finalmente, la categoría “vaca de pie” logró clasificar correctamente 34 de las 48 imágenes disponibles, logrando clasificar correctamente el 70.83% del total de imágenes de esta categoría.

Analizando el accuracy global de coincidencias en ambas camas nos dice que la cama B tiene mejor porcentaje de predicciones correctas con un 98%, mientras que en la cama A tiene 95% de las predicciones correctas. Esto puede ser

debido a que en la cama A históricamente hay menos camas vacías, por lo que hay mayor movimiento de un estado a otro.

7a.- Comparativo Entre Modelos

Aspecto	Modelo 3	Modelo 3.1	Modelo 4 (TL)
Transformaciones en imágenes	Redimensionamiento, giros horizontales y verticales, rotación aleatoria, Zoom out y Saturación (ColorJitter, factor de saturación = 2).	Mismas transformaciones pero con Brillo y Contraste (ColorJitter, factor de brillo = 0.3 y factor de contraste = 0.2) y sin contraste.	Igual
Épocas de entrenamiento	50	50	20
Pesos en función de pérdida	Cama vacía: 5 Vaca acostada: 1 Vaca de pie: 9	Cama vacía: 5 Vaca acostada: 1 Vaca de pie: 10	Cama vacía: 2 Vaca acostada: 4 Vaca de pie: 7
Learning rate	0.0001	0.0001	0.0005
F1-Score (Test)	96%	96%	95%
Accuracy en Test	96%	96%	95%
Accuracy promedio por cama	95%	80%	97%

Tabla 4: Comparativo de las características principales de los modelos y sus métricas.

Se realizó una comparación entre los modelos 3, 3.1 y 4 (modelo con Transfer Learning) evaluando distintos aspectos clave del proceso de entrenamiento y desempeño en el conjunto de prueba.

En términos de desempeño, tanto el Modelo 3 como el Modelo 3.1 lograron un F1-Score de 96% y un accuracy general del 96% sobre el conjunto de prueba. Por su parte, el Modelo 4 alcanzó un F1-Score del 95% y un accuracy de prueba del 95%, resultados ligeramente menores pero con una ventaja significativa en cuanto a eficiencia de entrenamiento.

Finalmente, considerando el accuracy promedio por cama, el Modelo 4 presentó el mejor desempeño, alcanzando un 97%, superior al 95% del Modelo 3 y al 80% registrado en el Modelo 3.1. Esto indica que el Modelo 4 fue más consistente al clasificar correctamente el estado individual de cada cama, lo cual es crítico para el análisis detallado del comportamiento de las vacas.

Aunque los tres modelos mostraron un desempeño similar en métricas globales, el Modelo 4 (con Transfer Learning) demostró ser más eficiente y robusto, especialmente al lograr mejores resultados en el análisis por cama con un número reducido de épocas de entrenamiento.

8. HALLAZGOS CON LOS NUEVOS DATOS

De manera individual, decidí enfocarme en los patrones a corto y largo plazo en las camas A y B del CAETEC.

8a.- Cantidad de Vacas Acostadas por Día




Figura 7: Suma total de cantidad de vacas en camas (A y B) por día.

La gráfica muestra el seguimiento diario del número de observaciones de vacas acostadas desde enero hasta finales de marzo de 2025, diferenciando entre dos tipos de camas (A en color turquesa y B en naranja).

Podemos observar que en general, la cama A muestra consistentemente un mayor número de observaciones de vacas acostadas que la cama B a lo largo del periodo analizado, lo que sugiere una clara preferencia de los animales por esta cama, puede ser debido a factores externos como el clima, cambios en la rutina del rancho o incluso, problemas con la infraestructura.

Se observa un pico muy pronunciado en la cama A (cerca de 140 observaciones), seguido de una disminución gradual. De mediados de enero a inicios de febrero se nota una reducción significativa en la ocupación de ambas camas, mientras que de febrero a marzo se nota un patrón más irregular con fluctuaciones constantes en ambas camas.

La cama A presenta mayor variabilidad, con valores que oscilan entre casi 0 y 140, mientras que la cama B es un poco más

estable con oscilaciones entre 0 y 120 mayormente. A mediados de febrero existe un momento donde ambas camas muestran picos simultáneos (con 120 observaciones aproximadamente). A finales de marzo hay nuevamente una alta ocupación en la cama A.

8b.- Cantidad de Camas Vacías por Día




Figura 8: Suma total de cantidad de camas vacías (A y B) por día.

En la gráfica podemos observar que ambas camas muestran patrones similares de disponibilidad con valores altos (entre 150 y 280 observaciones diarias), lo que indica que las camas permanecen desocupadas una parte significativa del tiempo.

Podemos ver que a principios de enero hay un incremento progresivo en ambas camas, alcanzando picos de aproximadamente 270 observaciones. A mediados de enero y principios de febrero hay un descenso notable en observaciones de camas vacías para ambas camas. De febrero a marzo, hay un patrón más estable, pero con fluctuaciones frecuentes y pronunciadas.

La cama B tiende a estar vacía con mayor frecuencia que la cama A en la mayoría del tiempo. Los valores para ambas camas

suelen oscilar entre 150 y 280 observaciones, con algunas caídas severas.

8c.- Duración Promedio de Ocupación por Estado (en Minutos)

```
Duración promedio por estado - Cama A:
Estado
cama_vacia      94.69
vaca_acostada    32.47
vaca_parada      8.74
Name: Duración (min), dtype: float64

Duración promedio por estado - Cama B:
Estado
cama_vacia      147.04
vaca_acostada    21.89
vaca_parada      9.01
Name: Duración (min), dtype: float64
```

Figura 9: Promedio de la duración continua por estado de la cama.

La cama B permanece vacía por periodos significativamente más largos (147.04 minutos) que la cama A (94.69 min), lo que sugiere una clara preferencia de las vacas por la cama A. Las vacas pasan más tiempo acostadas en la cama A (32.47 min) en comparación con la cama B (21.89 min), reforzando la preferencia por la cama A. Hay pocas diferencias en el tiempo que las vacas permanecen paradas en ambas camas (8.74 min en A y 9.01 min en B).

Por lo tanto, la cama A muestra un uso más intensivo y eficiente, con periodos más cortos de desocupación y estadías más largas de las vacas acostadas. Las vacas tienen una preferencia marcada por acostarse en la cama A, donde permanecen en promedio un 48% más de tiempo que en la cama B. El estado de vaca parada es similar en ambas camas, lo que sugiere que este estado puede estar más relacionado con comportamientos

exploratorios o transitorios que con la calidad o preferencia de la cama.

8d.- Distribución Horaria de Vacas Acostadas en Cama A




Figura 10: Suma total de vacas acostadas en la cama A en todo el día.

Se observa una clara preferencia de las vacas por acostarse en determinados momentos del día, con dos periodos claramente diferenciados:

- **Periodo nocturno-madrugada (23h-6h):** Alta frecuencia de vacas acostadas, con valores consistentemente superiores a 200 observaciones.
- **Periodo diurno (7h-22h):** Reducción significativa en la frecuencia, con valores que oscilan mayormente entre 50 y 130 observaciones.

El mayor número de observaciones ocurre a las 6h (aproximadamente 360 casos), seguido por las 5h (aproximadamente 330 casos). Este pico en la mañana sugiere una fuerte preferencia por descansar en las primeras horas de la mañana.

Las horas con menor cantidad de vacas acostadas son las 16h (con 15 observaciones aproximadamente) seguido de las 17h (con 25 observaciones aproximadamente). Esto puede indicar que

las vacas están realizando otras actividades (alimentación, socialización, ordeño, etc.).

Se observa un incremento gradual en el uso de la cama A desde las 18h, con un pico notable a las 23h. Esto sugiere un patrón donde vuelven al descanso al final del día.

8e.- Distribución Horaria de Vacas Acostadas en Cama B




Figura 11: Suma total de vacas acostadas en la cama B en todo el día.

Al igual que en la cama A, se observa una clara preferencia por utilizar la cama B durante la noche y la madrugada, con una división marcada entre los periodos:

- **Periodo nocturno-madrugada (23h-6h):** Alta frecuencia de vacas acostadas, con valores consistentemente superiores a 130 observaciones.
- **Periodo diurno (7h-22h):** Uso significativamente menor, con valores generalmente por debajo de 50 observaciones.

El mayor número de observaciones ocurre a las 5h (con 250 casos aproximadamente), seguido por las 3h (aproximadamente 245 casos). El periodo de máximo uso se concentra entre las 2h y las 6h, formando un bloque continuo de alta utilización.

Las horas con menor cantidad de vacas acostadas son las 17h (aproximadamente 10 observaciones) y 18h (aproximadamente 10 observaciones).

9. COMPARATIVO DE LOS HALLAZGOS ANTERIORES CON LOS ACTUALES

A continuación, se presenta el comparativo entre los hallazgos en la primera versión del proyecto del 2024 (con el modelo 3) vs. los mismos parámetros pero con el dataset del 2025 (con el modelo 4).

Cabe destacar que la cama B del modelo 3 (con el dataset del 2024) es la misma que la cama A del modelo 4 (con el dataset del 2025). Asimismo, la cama C del modelo 3 es la misma que la cama B del modelo 4.

9a.- Distribución Total de Imágenes Predichas por los Modelos




Figura 12: Distribución total de imágenes predichas (por el modelo 3) por cama con el total del dataset obtenido (9,634 imágenes).




Figura 13: Distribución total de imágenes predichas (por el modelo 4) por cama con el total del dataset obtenido (15,140 imágenes).

De acuerdo con ambas gráficas, la cama B(Modelo3)/A(Modelo 4) muestra un cambio notable en su uso:

- **En 2024:** Aproximadamente 60% era cama vacía, 35% era vaca acostada y 5% era vaca parada del total de observaciones en esta cama.
- **En 2025:** Aproximadamente 70% era cama vacía, 25% era vaca acostada y 5% era vaca parada.

Existe un aumento en el tiempo en que la cama permanece vacía (del 10% aproximadamente) y una disminución proporcional del tiempo con vacas acostadas, mientras que el comportamiento de vacas paradas se mantiene estable.

Pasando a la cama C(Modelo3)/A(Modelo 4) muestra un patrón consistente en su uso:

- **En 2024:** Aproximadamente 90% era cama vacía, 8% era vaca acostada y 2% era vaca parada del total de observaciones en esta cama.
- **En 2025:** Se tiene una distribución similar, manteniendo un patrón de uso mayoritariamente vacío.

Esta cama mantiene su característica de ser la cama menos preferida por las vacas, con un alto porcentaje de tiempo desocupada.

La diferencia observada en la cama B(Modelo 3)/A(Modelo 4) sugiere un cambio en las preferencias del ganado, con una disminución en el tiempo de uso para descanso.

De manera contraria, la cama C(Modelo 3)/B(Modelo 4) mantiene su perfil de baja utilización por parte del ganado en ambos años, lo que indica que hay factores persistentes que la hacen menos atractiva, esto pudiendo ser la pared del bebedero de a lado de esta cama.

9b.- Distribución Horaria Total de Vacas Acostadas Predichos por los Modelos




Figura 14: Distribución horaria total de vacas acostadas en todas las camas (resultados predichos por el modelo 3).




Figura 15: Distribución horaria total de vacas acostadas en todas las camas (resultados predichos por el modelo 4).

Ambos modelos muestran un patrón donde se muestra que el mayor uso de camas es durante la noche/madrugada y el menor uso es durante el día.

La gráfica del modelo 3 muestra una distribución más uniforme durante las horas nocturnas, con valores altos y sin picos extremos.

El modelo 4 presenta un pico muy marcado a las 5h y 6h (con 400 observaciones aproximadamente), con una concentración más definida de uso en esas horas.

En el modelo 3, se muestra un rango de observaciones que va de 150-450 por hora en los periodos de uso intenso de camas, mientras que en el modelo 4 se muestra un contraste más extremo, con valores que alcanzan 400 observaciones en las horas concurridas, pero descienden hasta menos de 50 en los periodos de menor uso.

A pesar de que el modelo 4 utilizó datos de solo dos camas (en comparación de 3 camas que se usaron en el modelo 3), los valores máximos de vacas acostadas son similares en ambos datasets, lo que sugiere que hay mayor concentración de uso de las camas disponibles en el dataset del 2025.

10. CONCLUSIÓN

Este estudio permitió comparar la distribución del comportamiento de descanso de vacas lecheras en el CAETEC mediante el análisis de imágenes capturadas en un entorno controlado, utilizando modelos de inteligencia artificial entrenados en datasets correspondientes a los años 2024 y 2025. Los resultados muestran patrones de comportamiento consistentes entre ambos

periodos, con una clara preferencia por el uso de las camas durante la noche y madrugada, y una disminución significativa durante el día.

Asimismo, se identificaron cambios en la frecuencia de uso de las camas entre los dos periodos evaluados. La cama con mayor preferencia en 2024 (modelo 3) experimentó una disminución en su utilización como zona de descanso en 2025 (modelo 4), mientras que la cama menos utilizada mantuvo su bajo nivel de ocupación. Estos hallazgos sugieren la influencia de factores ambientales o estructurales persistentes, como la proximidad a elementos del entorno (por ejemplo, el de la barda del bebedero), sobre las decisiones de descanso del ganado.

Pese a que el segundo modelo operó con un número menor de camas, se observaron valores máximos de ocupación horaria comparables a los del primer modelo. Esto indica una posible concentración del comportamiento de descanso en las camas disponibles, lo cual representa una oportunidad para optimizar el diseño de las instalaciones y promover un mayor bienestar animal.

En conjunto, los resultados validan la efectividad de los modelos de clasificación de imágenes para el monitoreo del comportamiento de vacas y ofrecen evidencia útil para mejorar la gestión del entorno físico en el sistema de producción lechera del CAETEC. Futuros trabajos podrían incorporar variables ambientales y de comportamiento adicionales, así como extender el análisis a un mayor número de camas o periodos estacionales, para

fortalecer la comprensión del bienestar animal en contextos productivos.

11. REFERENCIAS

1. Requena Serra, B. (s.f.). *Tamaño de la muestra*. Universo Fórmulas. Recuperado el 6 de abril de 2025, de <https://www.universoformulas.com/estadistica/descriptiva/tamano-muestra/>
2. IBM. (s.f.). *What is transfer learning?* IBM Think. Recuperado el 23 de abril de 2025, de <https://www.ibm.com/think/topics/transfer-learning#:~:text=Transfer%20learning%20is%20a%20machine%20task%20and%20For%20different%20dataset.>
3. Neptune.ai. (2022, 20 de diciembre). *Transfer learning: A complete guide with examples in images and text*. Neptune. <https://neptune.ai/blog/transfer-learning-guide-examples-for-images-and-text-in-keras>
4. Built In. (s.f.). *What is a fully connected layer in neural networks?* Built In. Recuperado el 26 de abril de 2025, de <https://builtin.com/machine-learning/fully-connected-layer>